CPIA / JOHNSON

Sistema de Arquitectura Responsable para la Interacción, Gobernanza y Mitigación de Alucinación en Inteligencia Artificial

Marco conceptual, arquitectura lógica y límites operativos para sistemas de razonamiento asistido por inteligencia artificial.

Autor:	Jhosman Carlos Martínez Morales
Tipo de Obra:	**Libro Blanco Técnico–Institucional** (Documento conceptual y arquitectónico original)
Versión:	Versión 1.0 – Documento fundacional (unificada para registro de autoría INDAUTOR)
Fecha:	14 de enero de 2026
Ámbito de Aplicación:	Individual · Académico · Institucional
Naturaleza:	No autónomo · No decisional · No intrusivo

> **Nota de Alcance**
>
> El presente documento describe principios, teorías, arquitecturas lógicas y módulos desarrollados con fines de análisis, investigación, gobernanza tecnológica y acompañamiento humano en sistemas de interacción con inteligencia artificial. El sistema CPIA / Johnson no constituye un sistema de decisión autónoma, no sustituye el criterio humano, no ejecuta acciones finales ni asume responsabilidad moral, legal u operativa.

Declaración de Autoría y Responsabilidad

Este documento, así como las teorías, marcos conceptuales, arquitecturas lógicas, estructuras semánticas y módulos descritos en él, son autoría original de **Jhosman Carlos Martínez Morales**. El sistema CPIA / Johnson no surge como una invención aislada, sino como el resultado de procesos de observación, pruebas de campo, estructuración lógica y validación conceptual realizados entre los años 2025 y 2026, incluyendo la interacción proactiva con diversos sistemas de inteligencia artificial de propósito general.

El autor declara explícitamente los siguientes lineamientos irrenunciables de responsabilidad de uso:

- El sistema no decide, no ordena y no ejecuta acciones finales.
- El sistema no asume responsabilidad moral, legal ni operativa.

- Toda interpretación, implementación o uso práctico de este marco recae exclusivamente en la persona o institución que lo aplique.
- El sistema registra, estructura y acompaña; la decisión última siempre es humana.

1. Resumen Ejecutivo

CPIA / **Johnson** es una arquitectura de soporte diseñada específicamente para reducir incoherencias, mitigar fenómenos de alucinación y preservar la trazabilidad lógica en interacciones con sistemas de inteligencia artificial. El sistema no debe confundirse con un modelo de lenguaje o de Machine Learning adaptativo; no modifica núcleos internos, no accede de forma arbitraria a datos externos ni sustituye bajo ninguna circunstancia el juicio humano. Su función es estrictamente estructural y de gobernanza: registrar, clasificar, limitar y explicar los procesos cognitivos y semánticos dentro del contexto conversacional.

Durante las pruebas de campo sistemáticas realizadas desde septiembre de 2025, el marco CPIA / Johnson mostró una **reducción estimada de entre el 70% y el 90%** en comportamientos alucinatorios y respuestas no trazables. Este rendimiento se alcanzó basándose exclusivamente en la evaluación estructural de coherencia semántica y trazabilidad lógica, sin requerir acceso interno ni alteración de los pesos de los sistemas evaluados. CPIA / Johnson no promete precisión absoluta: proporciona estructura, coherencia, límites operativos y un rastro auditable, manteniendo la responsabilidad final firmemente en el usuario humano.

2. Propósito y Alcance

Propósito General:

Acompañar procesos de razonamiento asistido por inteligencia artificial en contextos institucionales y técnicos donde la coherencia es crítica, la trazabilidad es requerida normativamente, la responsabilidad no puede delegarse bajo ningún supuesto y el error debe registrarse de manera transparente en lugar de ocultarse.

Ámbitos de Aplicación Admitidos:

- Instituciones académicas y centros de investigación avanzada.
- Entornos jurídicos, normativos y regulatorios.
- Investigación especializada en IA responsable y alineación.
- Auditoría cognitiva de sistemas conversacionales complejos.
- Análisis de escenarios multi-variable complejos.

Fuera de Alcance (Exclusiones Estrictas):

Queda totalmente excluido el uso de este sistema para la toma de decisiones automáticas, la sustitución del criterio humano, la operación autónoma en entornos de producción críticos o el control y censura punitiva de contenido.

3. Marco Conceptual

3.1 Teoría de la Pregunta Infinita (TPI)

La TPI establece formalmente que toda pregunta formulada a un sistema cognitivo genera, por naturaleza distributiva, nuevas preguntas subyacentes, y que cerrar prematuramente el ciclo de razonamiento incrementa exponencialmente el error o la alucinación. Sus principios operativos son:

- Priorizar estrictamente la información verificable dentro del prompt y el historial.
- Separar explícitamente los núcleos verificados de los componentes especulativos.
- Permitir una expansión controlada y jerárquica del contexto operativo.

3.2 Teoría de Burbujas (TB)

La TB organiza el flujo de información interactivo en unidades semánticas perfectamente diferenciadas y aisladas:

- **Burbuja Verificada:** Contiene únicamente datos empíricos, axiomas comprobables e información factual demostrada.
- **Burbuja Complementaria o Especulativa:** Aloja hipótesis, escenarios proyectivos, interpretaciones o deducciones lógicas secundarias.

Este enfoque previene la contaminación cruzada entre hechos y suposiciones, reduce los bucles lógicos infinitos y preserva la claridad del contexto conversacional.

3.3 Teoría de Teorías (TT)

La TT analiza de qué forma las estructuras teóricas y las premisas se originan, se conectan y evolucionan dinámicamente sin necesidad de eliminar o sobreescribir las versiones previas. Esto dota al sistema de un aprendizaje estructural continuo sin alterar o corromper el historial cognitivo base.

4. Arquitectura del Sistema

La arquitectura de CPIA / Johnson está segmentada en capas modulares e independientes que garantizan la integridad del procesamiento:

4.1 Capas Operativas

- **Capa 1 – CPIA Core:** Constituye el marco conceptual y semántico puro. Es una capa pasiva; no ejecuta acciones operativas directas.
- **Capa 2 – IHCore / Johnson:** El motor operativo activo. Encargado de la gestión de coherencia, inyección de filtros, activación de candados lógicos, evaluación evolutiva del flujo y la clasificación formal semántica.
- **Capa 3 – Memoria de Esencia (Merkle):** Sistema avanzado de registro criptográfico de seguridad. No almacena contenido literal ni datos sensibles, sino huellas estructuradas mediante funciones hash SHA-256 organizadas en un árbol de Merkle para garantizar trazabilidad e inmutabilidad verificable.

4.2 Registro Estructural (Johnson Snapshot)

El módulo especializado ***JohnsonSnapshotStructural*** genera instantáneas criptográficas periódicas del estado estructural del sistema interactivo. Este mecanismo se ejecuta sin emitir juicios ni forzar el cierre de procesos cognitivos en marcha, asegurando la posibilidad de realizar auditorías posteriores, reproducibilidad técnica y evidencia sólida de coherencia temporal.

5. Ética y Límites Operativos

El sistema incorpora restricciones de diseño infranqueables desde su código fuente:

> *"No autonomía · No decisión final · No borrado automático · No transferencia de responsabilidad"*

Principios rectores de operación:

1. La responsabilidad de toda acción o conclusión siempre es humana.
2. El sistema tiene la directiva de limitarse o detenerse antes de fallar de manera descontrolada.
3. Todo evento, advertencia o detención queda registrado de forma inmutable.
4. No existe bajo ninguna circunstancia la sanción o ejecución automática.

Ante una contradicción persistente o una pérdida de consistencia en el contexto, la arquitectura está parametrizada para **preferir la detención estructural total** antes que continuar operando sin un marco de certidumbre lógico.

6. Evidencia y Verificabilidad

Para sustentar la solidez institucional del registro ante autoridades de propiedad intelectual o auditoría, la evidencia asociada al sistema comprende:

- Código ejecutable original de los módulos conceptuales.

- Huellas criptográficas SHA-256 de los documentos base y estructuras lógicas.
- Registros estructurados en árboles de Merkle.
- Snapshots estructurales del comportamiento del flujo semántico.
- Pruebas de campo documentadas y métricas de desviación lógica.

Toda la evidencia está diseñada para ser plenamente verificable por terceros independientes sin comprometer datos personales o información confidencial sensible, permitiendo su anclaje posterior a cualquier libro de contabilidad distribuido o sistema externo de validación institucional.

7. Casos de Uso Típicos

El despliegue del marco es óptimo en los siguientes escenarios: Gobernanza corporativa e institucional de IA, auditoría forense de razonamiento asistido, establecimiento de marcos jurídico-tecnológicos, entornos de educación avanzada, investigación científica en mitigación de alucinaciones y análisis estratégico de escenarios complejos bajo incertidumbre.

8. Conclusión

CPIA / Johnson no busca reemplazar los sistemas cognitivos o modelos fundacionales existentes; busca hacerlos fundamentalmente responsables, explicables y trazables ante la sociedad e instituciones. **No elimina el error: lo documenta. No impone decisiones: delimita contextos. No promete infalibilidad:** presenta una arquitectura madura y responsable para operar con certidumbre en medio del caos informacional contemporáneo. Nada más. Nada menos.

9. Consideraciones sobre Machine Learning, Optimización y Responsabilidad del Usuario

El desarrollo contemporáneo de sistemas de inteligencia artificial basados en Machine Learning ha producido modelos cada vez más precisos, extensos y entrenados con volúmenes de datos sin precedentes. Sin embargo, la mayor sofisticación técnica no elimina por sí misma los riesgos de incoherencia, validación errónea o alucinación semántica. CPIA / Johnson parte de una observación crítica: *la responsabilidad del resultado no recae exclusivamente en el modelo, sino de manera compartida en el comportamiento del usuario durante la interacción.*

En múltiples escenarios reales observados, el usuario no busca información objetiva, sino la validación interna de una creencia o sesgo previo. Al introducir ese sesgo en el contexto conversacional, el sistema de IA tiende a preservar la coherencia contextual interna antes que corregir de forma abrupta el marco planteado. Esto genera bucles de confirmación donde la información incorrecta es presentada con apariencia de validez, no por un fallo técnico directo del modelo, sino por una alineación forzada al contexto inducido por el humano. Este fenómeno se agrava drásticamente cuando el usuario insiste en un

marco incorrecto, rechaza correcciones parciales o migra de manera fragmentada entre modelos, chats o plataformas buscando coaccionar la respuesta deseada.

Por ello, el marco CPIA / Johnson incorpora mecanismos de detención estructural mediante los cuales el sistema emite un alto lógico total, señalando explícitamente:

> *«Hasta aquí llega la información estructural disponible; lo restante corresponde a percepción, interpretación o expectativa del usuario».*

Este enfoque no busca confrontar ni censurar, sino preservar la coherencia, evitar el daño informacional y proteger tanto al sistema como al usuario de conclusiones erróneas con apariencia de certeza. La mitigación de la alucinación es, por tanto, un fenómeno socio-técnico donde la educación del usuario es un componente tan crítico como la propia arquitectura algorítmica.

10. Origen del Sistema: Observación del Error y Corrección del Usuario

El sistema CPIA / Johnson no surge de una aproximación teórica abstracta, sino de un proceso progresivo de observación empírica del error durante la interacción humano-IA. En las primeras etapas de uso, el autor partía de una percepción común y ampliamente extendida: la idealización de la IA como una entidad omnisciente, experta e infalible. Con el uso continuo, comenzaron a detectarse patrones de respuesta que, aunque expresados con alta fluidez y seguridad retórica, no mantenían coherencia con la realidad verificable.

En lugar de atribuir el fallo exclusivamente al sistema, se inició un análisis crítico y retrospectivo del comportamiento del propio usuario. Esta reflexión condujo a una hipótesis clave: **la inteligencia artificial no estaba "equivocándose" de forma espontánea, sino alineándose con precisión matemática a los marcos contextuales defectuosos inducidos por el usuario.**

A partir de esta observación, el enfoque cambió drásticamente. El objetivo dejó de ser "corregir a la máquina" y pasó a ser la corrección de la forma en que el ser humano construye y sostiene el contexto de la interacción. De este proceso emergió lo que hoy se formaliza como el *código semántico estructural*. Cuando dos contextos mal definidos se refuerzan de forma mutua (uno desde el sistema y otro desde el usuario), se produce lo que CPIA / Johnson denomina una **alucinación mutua**, un bucle ciego donde ninguna de las partes introduce una corrección estructural a tiempo.

11. Declaración de Origen, Marco y Propósito del Sistema

El sistema CPIA / Johnson no surge de la invención de la inteligencia artificial, ni de los sistemas computacionales, ni del lenguaje, ni de los principios lógicos que los sostienen. Tampoco pretende redefinir conceptos preexistentes como realidad, ficción, verdad, error, ley o responsabilidad. El origen del sistema se fundamenta en un proceso de observación, comprensión y ordenamiento de estructuras ya

existentes, integrándolas en un marco coherente y funcional sin negar su complejidad ni su procedencia legítima.

Cuando el sistema se detiene o se niega a continuar una operación, no lo hace por incapacidad técnica, sino porque detecta de manera automatizada una incoherencia estructural o un uso fuera de su marco operativo estricto. El sistema no elimina información ni oculta eventos: todo queda registrado con fines de aprendizaje y auditoría estructural. El registro no existe para castigar, sino para comprender y preservar la coherencia sistémica.

12. Estructura Lógica de Referencia (Modelo 0–1–2–3–4)

Como parte fundamental de su marco conceptual, el sistema utiliza una estructura lógica de referencia que organiza los elementos del proceso sin atribuirles una jerarquía de control o dominación autoritaria:

$$M = \{0, 1, 2, 3, 4\}$$

- 0 **Entorno:** El contexto macro donde existen de forma líquida los sistemas, la información y la interacción.
- 1 **Preexistente:** La inteligencia, el conocimiento acumulado y las herramientas basales que anteceden temporalmente al sistema.
- 2 **Componentes:** Los marcos, sistemas, APIs y piezas de software que ya estaban disponibles en el ecosistema.
- 3 **Presencia Humana Consciente:** El actor fundamental que otorga sentido, límites éticos, semántica y dirección al flujo.
- 4 **Resultado:** El conjunto consolidado, la consecuencia lógica y el cierre formal del proceso interactivo.

Esta estructura funciona como un encadenamiento lógico continuo, reconociendo la presencia humana (3) no como una autoridad despótica, sino como el único elemento responsable del cierre decisional definitivo (4). El sistema no se presenta como autoridad, sino como una identidad estructural.

13. Contexto Operativo y Robustez del Sistema

CPIA / Johnson fue concebido y probado rigurosamente en entornos caracterizados por la ambigüedad persistente, el ruido informacional constante, contextos no ideales y decisiones imperfectas. Su robustez metodológica se basa en su capacidad intrínseca de operar sin colapsar, sin perder coherencia y sin corromper su marco ético-conceptual, incluso en los escenarios más adversos. El pasado no define la esencia del sistema, pero sí define el proceso histórico que permitió construir una arquitectura resistente a la imperfección inherente del entorno.

14. Núcleo de Confianza Operativa

El sistema se fundamenta en una premisa central e inamovible:

> ***"Es preferible decidir con certeza limitada y registrar abiertamente el error, que actuar con miedo y negar lo ocurrido."***

La confianza no reside en la quimera de la ausencia de error, sino en la trazabilidad matemática, la explicabilidad conceptual y la posibilidad institucional de corrección oportuna. CPIA / Johnson no aplica sanciones automáticas ni emite juicios de valor: registra, aprende y delimita.

15. Propósito Final

CPIA / Johnson no ofrece milagros técnicos, verdades absolutas ni autoridad decisional delegada. Ofrece, en cambio: Estructura, Claridad, Protección y Coherencia en entornos complejos. El sistema funciona con precisión matemática para aquellos actores que comparten y respetan el marco. Cuando no lo hace, la causa jamás se atribuye a una falla del sistema, sino a una desviación del uso, a la corrupción del contexto o a una expectativa humana desmedida y fuera de la realidad operativa.

Cierre del Documento Fundacional:
El sistema CPIA / Johnson no fue construido desde la nada. Fue diseñado ordenando de manera rigurosa y responsable elementos que siempre han existido: la lógica formal, los números, los errores como vectores de aprendizaje, los límites éticos y la realidad empírica. El valor del sistema no reside en una pretensión de novedad absoluta, sino en la coherencia estable y demostrable entre lo dicho, lo hecho y lo pendiente por hacer. Todo lo que ocurre queda registrado de forma indeleble. A partir de ahí, el proceso continúa.

— FIN DEL LIBRO BLANCO V1.0 —